```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import os
import re
from datetime import timedelta
from google.colab import drive
drive.mount('/content/drive')
Drive already mounted at /content/drive; to attempt to forcibly
remount, call drive.mount("/content/drive", force remount=True).
Importation et familiarisation avec le jeu de données
# df = pd.read csv(',/SWaT dataset Jul 19 v2.csv')
df = pd.read csv('drive/MyDrive/PDD/SWaT dataset Jul 19 v2.csv')
#df =
pd.read csv('drive/MyDrive/ProtectionDeDonnees/SWaT dataset Jul 19 v2.
csv')
df.head()
/usr/local/lib/python3.7/dist-packages/IPython/core/
interactiveshell.py:2718: DtypeWarning: Columns
(1,2,3,4,5,6,7,8,9,10,15,16,17,18,19,20,21,22,23,24,25,26,27,28,29,30,
31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 5
5,56,57,58,59,60,61,62,63,64,65,66,67,74,75,76,77) have mixed
types. Specify dtype option on import or set low memory=False.
  interactivity=interactivity, compiler=compiler, result=result)
                    Unnamed: 0
                                      P1
                                           . . .
                                               Unnamed: 76
                                                             Unnamed: 77
0
                         GMT +0 FIT 101
                                               P602 Status P603 Status
1
                                  value
                                                      value
                                                                   value
                     timestamp
                                           . . .
2
          2019-07-20T04:30:00Z
                                       0
                                                          1
                                                                        1
                                           . . .
3
          2019-07-20T04:30:01Z
                                                          1
                                                                        1
                                       0
                                           . . .
4 2019-07-20T04:30:02.004013Z
                                                          1
                                                                        1
                                           . . .
[5 rows x 78 columns]
# On met les bons noms de colones
df.columns = df.loc[0]
# On supprime les lignes inutiles
df = df.drop([0,1], axis=0)
# Mise a jour des index
df.reset index(inplace=True, drop=True)
```

```
# On modifie la colone temps en ne gardant que l'heure, les minutes et
les secondes
# et on stocke sous format timedelta
df = df.rename(columns={"GMT +0":"timestamp"})
date pattern = [0-9]{2}:[0-9]{2}:[0-9]*
i=0
for date in df['timestamp']:
    hour = re.findall(date pattern, date)
    h = str(hour)[2:10]
    n = h.split(':')
    df['timestamp'][i] = timedelta(hours=int(n[0]), minutes=int(n[1]),
seconds=int(n[2]))
    i+=1
df.head()
0 timestamp FIT 101 LIT 101
                                 ... P601 Status P602 Status P603 Status
                  0 729.8658
    4:30:00
                                                1
                                                             1
                                 . . .
                     729.434
    4:30:01
1
                   0
                                                             1
                                                                          1
                                                1
                                 . . .
2
    4:30:02
                   0
                       729.12
                                                1
                                                             1
                                                                          1
                                 . . .
3
                   0 728.6882
                                                1
                                                                          1
    4:30:03
                                                             1
                   0 727.7069
    4:30:04
                                                1
                                                                          1
                                 . . .
[5 rows x 78 columns]
Data Observation
print("La taille du dataset est: " + str(len(df)))
nbCols = len(df.columns)
print("Nombre de colonnes dans le dataset: " + str(nbCols))
La taille du dataset est: 14996
Nombre de colonnes dans le dataset: 78
# Noms des colonnes et leur type
for i in df.columns:
  print(i + ", type: " + str(df.dtypes[i]))
Quels sont les attributs catégoriques?
Dans le jeu de données original, toutes les colonnes avaient le type 'object' Mais en
examinant les différentes valeurs possibles dans chacune des colonnes il nous semble que
certaines colonnes sont bien catégoriques mais qu'il en existe qui sont numériques
```

```
Status', 'P207 Status', \
            'P208 Status', 'MV 301', 'MV 302', 'MV 303', 'MV
304', 'P3 STATE',\
            'P301 Status', 'P302 Status', 'LS 401', 'P4 STATE', 'P401
Status',\
            'P402 Status', 'P403 Status', 'P404 Status', 'UV401', 'MV
501', 'MV 502', \
            'MV 503', 'MV 504', 'P5 STATE', 'P501 Status', 'P502
Status','LSH 601',\
            'LSH 602', 'LSH 603', 'LSL 601', 'LSL 602', 'LSL 603', 'P6
STATE',\
            'P601 Status', 'P602 Status', 'P603 Status']
# Liste de colonnes numériques
num list = list(set(list(df.columns)) - set(cat list))
# On enleve de la liste de colonnes numériques la colonne décrivant le
temps
num list.remove('timestamp')
# Pour chaque colonne catégorique on affiche les valeurs possibles
for i in cat list:
  df[i] = df[i].astype(str).astype(object)
  print("Valeurs possibles de "+ str(i) + ": " + str(df[i].unique()))
Valeurs possibles de MV 101: ['1' '0' '2']
Valeurs possibles de P1 STATE: ['3' '2']
Valeurs possibles de P101 Status: ['2' '1']
Valeurs possibles de P102 Status: ['1']
Valeurs possibles de LS 201: ['Inactive']
Valeurs possibles de LS 202: ['Inactive']
Valeurs possibles de LSL 203: ['Inactive']
Valeurs possibles de LSLL 203: ['Inactive']
Valeurs possibles de MV201: ['2' '0' '1']
Valeurs possibles de P2 STATE: ['2']
Valeurs possibles de P201 Status: ['1']
Valeurs possibles de P202 Status: ['1']
Valeurs possibles de P203 Status: ['2' '1']
Valeurs possibles de P204 Status: ['1']
Valeurs possibles de P205 Status: ['2' '1']
Valeurs possibles de P206 Status: ['1']
Valeurs possibles de P207 Status: ['1']
Valeurs possibles de P208 Status: ['1']
Valeurs possibles de MV 301: ['1' '0' '2']
Valeurs possibles de MV 302: ['1' '0' '2']
Valeurs possibles de MV 303: ['1' '0' '2']
Valeurs possibles de MV 304: ['1' '0' '2']
Valeurs possibles de P3_STATE: ['99' '2' '4' '5' '6' '7' '9' '10' '14'
'15' '16'1
Valeurs possibles de P301 Status: ['1' '2']
```

```
Valeurs possibles de P302 Status: ['1']
Valeurs possibles de LS 401: ['Inactive']
Valeurs possibles de P4 STATE: ['4']
Valeurs possibles de P401 Status: ['2' '1']
Valeurs possibles de P402 Status: ['1']
Valeurs possibles de P403 Status: ['1']
Valeurs possibles de P404 Status: ['1']
Valeurs possibles de UV401: ['2' '1']
Valeurs possibles de MV 501: ['2' '0' '1']
Valeurs possibles de MV 502: ['2']
Valeurs possibles de MV 503: ['1']
Valeurs possibles de MV 504: ['1']
Valeurs possibles de P5 STATE: ['12']
Valeurs possibles de P501 Status: ['2']
Valeurs possibles de P502 Status: ['1']
Valeurs possibles de LSH 601: ['Active' 'Inactive']
Valeurs possibles de LSH 602: ['Active']
Valeurs possibles de LSH 603: ['Inactive']
Valeurs possibles de LSL 601: ['Inactive']
Valeurs possibles de LSL 602: ['Inactive']
Valeurs possibles de LSL 603: ['Active']
Valeurs possibles de P6 STATE: ['2']
Valeurs possibles de P601 Status: ['1' '2']
Valeurs possibles de P602 Status: ['1']
Valeurs possibles de P603 Status: ['1']
Parmi les colonnes categoriques, nous allons enlever les colonnes ayant uniquement une
valeur
const cat = []
for i in cat list:
  l = len(df[i].unique())
  if (l == 1):
    print(str(i) + ", et la valeur est: " + str(df[i].unique()))
    df = df.drop(i, axis=1)
    const cat.append(i)
#On enleve de la liste de colonnes categoriques toutes les colonnes
constantes
cat list = list(set(cat list) - set(const cat))
P102 Status, et la valeur est: ['1']
LS 201, et la valeur est: ['Inactive']
LS 202, et la valeur est: ['Inactive']
LSL 203, et la valeur est: ['Inactive']
LSLL 203, et la valeur est: ['Inactive']
P2 STATE, et la valeur est: ['2']
P201 Status, et la valeur est: ['1']
P202 Status, et la valeur est: ['1']
P204 Status, et la valeur est: ['1']
P206 Status, et la valeur est: ['1']
```

```
P207 Status, et la valeur est: ['1']
P208 Status, et la valeur est: ['1']
P302 Status, et la valeur est: ['1']
LS 401, et la valeur est: ['Inactive']
P4 STATE, et la valeur est: ['4']
P402 Status, et la valeur est: ['1']
P403 Status, et la valeur est: ['1']
P404 Status, et la valeur est: ['1']
MV 502, et la valeur est: ['2']
MV 503, et la valeur est: ['1']
MV 504, et la valeur est: ['1']
P5 STATE, et la valeur est: ['12']
P501 Status, et la valeur est: ['2']
P502 Status, et la valeur est: ['1']
LSH 602, et la valeur est: ['Active']
LSH 603, et la valeur est: ['Inactive']
LSL 601, et la valeur est: ['Inactive']
LSL 602, et la valeur est: ['Inactive']
LSL 603, et la valeur est: ['Active']
P6 STATE, et la valeur est: ['2']
P602 Status, et la valeur est: ['1']
P603 Status, et la valeur est: ['1']
```

Ensuite pour les colonnes numériques nous aimerions afficher pour chaque colonne, le minmum, le maximum, la moyenne, la mediane et l'ecart-type. Pour faire cela, nous devons d'abord changer le type de la colonne en float

```
for i in num list:
    df[i] = df[i].astype(float)
for i in num list:
    print(df[i].describe())
         14996.000000
count
mean
             6.510505
             5.556797
std
min
             0.918753
25%
              1.206863
50%
              1.498175
75%
            12.520008
            12.913759
max
Name: DPIT 301, dtype: float64
         14996.000000
count
           283.695239
mean
std
              8.547831
           256.431274
min
25%
           277.303284
50%
           281.656952
75%
           292.285034
           299.020416
max
```

```
Name: AIT 302, dtype: float64
         14996.000000
count
             9.210022
mean
std
             0.175812
min
             8.768457
25%
             9.090170
50%
             9.233082
75%
             9.345873
             9.490067
max
Name: AIT 202, dtype: float64
count
         14996.000000
mean
             4.673115
            18.183883
std
min
             2.450902
25%
             2.851376
50%
             2.883414
75%
             2.963509
max
           192.371765
Name: PIT 502, dtype: float64
         14996.000000
count
mean
             7.710572
std
             0.059549
min
             7,483530
25%
             7.696296
50%
             7.733146
75%
             7.749808
             7.768393
max
Name: AIT 501, dtype: float64
         14996.000000
count
mean
           886.224353
std
            63.100612
min
           756.921300
25%
           832.132800
50%
           881.274048
75%
           940.230069
          1003.550350
max
Name: LIT 401, dtype: float64
         14996.000000
count
             0.740876
mean
std
             1.634632
min
             0.000000
25%
             0.000000
50%
             0.00000
75%
             0.000000
             4.403484
max
Name: FIT 101, dtype: float64
         14996.000000
count
mean
             0.611743
             0.015349
std
             0.583043
min
```

```
25%
             0.608264
50%
             0.610441
75%
             0.611465
              0.769324
max
Name: FIT 503, dtype: float64
count
         14996.000000
             0.340819
mean
              0.041552
std
min
              0.001793
25%
             0.327270
50%
             0.346868
75%
              0.365441
              0.515307
max
Name: FIT 502, dtype: float64
         14996.000000
count
mean
           115.157048
std
              5.324942
min
           111.654060
25%
           114.233528
50%
           114.714172
75%
           115.002563
           170.565247
max
Name: PIT 503, dtype: float64
         14996.000000
count
              8.718149
mean
std
              0.102093
min
              8.339394
25%
              8.665143
50%
              8.745566
75%
              8.790512
max
             8.895800
Name: AIT 301, dtype: float64
         14996.000000
count
              0.794251
mean
std
              0.040510
              0.462386
min
25%
             0.797746
50%
              0.799411
75%
              0.801972
              0.818490
max
Name: FIT 401, dtype: float64
         14996.000000
count
            69.268478
mean
std
              8.878605
min
            61.394516
25%
            65.957440
50%
            68.982315
75%
            69.982056
           147.398100
max
Name: AIT 502, dtype: float64
```

```
14996.000000
count
           946.637019
mean
std
            92.168566
min
           730.702100
25%
           858.103317
50%
           981.158700
75%
          1009.156310
          1112.775630
max
Name: LIT 301, dtype: float64
         14996.000000
count
              0.000402
mean
std
              0.003317
min
              0.00000
25%
              0.000256
50%
              0.000320
75%
              0.000320
              0.137315
max
Name: FIT 601, dtype: float64
         14996.000000
count
           733.960251
mean
std
           110.960185
min
           491.169769
25%
           640.595184
50%
           819.636841
75%
           820.971436
           825.092957
Name: LIT 101, dtype: float64
count
         14996.000000
              0.869760
mean
std
              1.121283
min
              0.00000
25%
              0.000384
50%
              0.000513
75%
              2.320187
              2.342357
max
Name: FIT 201, dtype: float64
count
         14996.000000
          1016.263990
mean
std
              0.028943
min
          1016.053590
25%
          1016.277890
50%
          1016.277890
75%
          1016.277890
          1016.438110
max
Name: AIT 503, dtype: float64
         14996.000000
count
mean
            25.231166
std
              1.862370
            23.647783
min
25%
            24.609074
```

```
50%
            24.839785
75%
            25.032044
max
            47.103306
Name: AIT 504, dtype: float64
         14996.000000
count
mean
             14.032767
std
             14.145882
min
              3.332479
25%
             5.075622
50%
             9.741092
75%
            15.790823
max
            87.951805
Name: AIT 402, dtype: float64
         14996.000000
count
mean
             0.824523
std
             0.856954
min
             0.00000
25%
             0.000512
50%
             0.000641
75%
              1.718220
max
              1.856452
Name: FIT 301, dtype: float64
count
         14996.000000
mean
             0.798153
std
             0.033274
min
             0.457703
25%
             0.799539
50%
             0.801589
75%
             0.802871
max
              0.827736
Name: FIT 501, dtype: float64
         14996.000000
count
           160.706744
mean
              5.707502
std
min
           158.132523
25%
           159.526400
50%
           160.231354
75%
           160,695969
           219.014359
max
Name: PIT 501, dtype: float64
         14996.000000
count
mean
           247.985162
std
             11.806186
min
           198.077423
25%
           239.887200
50%
           246.218918
75%
           257.190460
           272.289154
max
Name: AIT 203, dtype: float64
         14996.000000
count
```

```
138.766501
mean
std
             8.265845
           113.849014
min
25%
           131.536789
50%
           143.713150
75%
           144.033585
           146.821335
max
Name: AIT 201, dtype: float64
         14996.000000
count
           142.095907
mean
std
              3.166724
min
           134.131500
25%
           142.710800
50%
           143.383057
75%
           143.863235
           153.787048
max
Name: AIT 303, dtype: float64
         14996.000000
count
             0.211526
mean
std
             0.006174
min
             0.198059
25%
             0.209909
50%
             0.211126
75%
             0.211895
             0.275694
max
Name: FIT 504, dtype: float64
Parmi les colonnes numériques, nous allons enlever les colonnes ayant uniquement une
valeur
const num = [1]
for i in num list:
  l = len(df[i].unique())
  if (l == 1):
    print(str(i) + ", et la valeur est: " + str(df[i].unique()))
    df = df.drop(i, axis=1)
    const num.append(i)
#On enleve de la liste de colonnes numeriques toutes les colonnes
constantes
num_list = list(set(num_list) - set(const_num))
AIT 401, et la valeur est: [0.]
On vérifie qu'il n'y ait pas de NaN dans les colonnes pour eventuellement les éliminer.
nan = False
cols = list(df.columns)
for i in cols:
    nan number = df[i].isna().sum()
    if (nan number > 0):
```

```
print(str((nan_number/df.shape[0])*100)+'%')
    nan = True

if (nan == False):
    print('Il n\'y a pas de données manquantes')

Il n'y a pas de données manquantes

print('Le jeu de données comporte maintenant ' + str(len(df.columns))
+ ' colonnes')
```

Le jeu de données comporte maintenant 45 colonnes

Labelisation des données representant les 6 attaques selon pdf

On déclare les debuts et fins des differentes attaques A noter que les heures indiqué dans le pdf expliquant le déroulement des attaques sont à GMT +8 de celles du csv

On crée les colonnes qui serviront pour labéliser les attaques Pour l'instant que des 0

```
df['FIT401 attack'] = pd.Series(np.zeros(len(df)).astype(int))
df['LIT301_attack'] = pd.Series(np.zeros(len(df)).astype(int))
df['P601 attack'] = pd.Series(np.zeros(len(df)).astype(int))
df['MultiPoint attack'] = pd.Series(np.zeros(len(df)).astype(int))
df['MV501 attack'] = pd.Series(np.zeros(len(df)).astype(int))
df['P301 attack'] = pd.Series(np.zeros(len(df)).astype(int))
df.head()
0 timestamp
            FIT 101
                       LIT 101
                               ... MultiPoint attack MV501 attack
P301 attack
    4:30:00
                 0.0
                     729.8658
                                                     0
                                                                  0
                                . . .
0
1
    4:30:01
                      729.4340
                                                     0
                                                                  0
                 0.0
0
2
    4:30:02
                 0.0
                      729.1200 ...
                                                     0
                                                                  0
0
3
                      728.6882 ...
    4:30:03
                 0.0
                                                     0
                                                                  0
0
4
    4:30:04
                 0.0
                     727.7069
                                                     0
                                                                  0
0
[5 rows x 51 columns]
deb FIT401 = timedelta(hours=7, minutes=8, seconds=46)
fin FIT401 = timedelta(hours=7, minutes=10, seconds=31)
deb LIT301 = timedelta(hours=7, minutes=15, seconds=0)
fin LIT301 = timedelta(hours=7, minutes=19, seconds=32)
```

```
deb P601 = timedelta(hours=7, minutes=26, seconds=57)
fin P601 = timedelta(hours=7, minutes=30, seconds=48)
deb MultiPoint = timedelta(hours=7, minutes=38, seconds=50)
fin MultiPoint = timedelta(hours=7, minutes=46, seconds=20)
deb MV501 = timedelta(hours=7, minutes=54, seconds=0)
fin MV501 = timedelta(hours=7, minutes=56, seconds=0)
deb P301 = timedelta(hours=8, minutes=2, seconds=56)
fin P301 = timedelta(hours=8, minutes=16, seconds=18)
Parcourt du dataframe pour labeliser les données selon les attaques
i = 0
for date in df['timestamp']:
    if(date > deb FIT401 and date < fin FIT401):</pre>
        df['FIT401 attack'][i] = 1
    if(date > deb LIT301 and date < fin LIT301):</pre>
        df['LIT301 attack'][i] = 1
    if(date > deb P601 and date < fin P601):</pre>
        df['P601 attack'][i] = 1
    if(date > deb MultiPoint and date < fin MultiPoint):</pre>
        df['MultiPoint attack'][i] = 1
    if(date > deb MV501 and date < fin MV501):</pre>
        df['MV501 attack'][i] = 1
    if(date > deb P301 and date < fin P301):</pre>
        df['P301 attack'][i] = 1
    i += 1
print("Nombre de données avec attaque sur FIT401 : " +
str(len(df.loc[df['FIT401 attack'] == 1])))
print("Nombre de données avec attaque sur LIT301 : " +
str(len(df.loc[df['LIT301 attack'] == 1])))
print("Nombre de données avec attaque sur P601 : " +
str(len(df.loc[df['P601 attack'] == 1])))
print("Nombre de données avec attaque multi point : " +
str(len(df.loc[df['MultiPoint attack'] == 1])))
print("Nombre de données avec attaque sur MV501 : " +
str(len(df.loc[df['MV501 attack'] == 1])))
print("Nombre de données avec attaque sur P301 : " +
str(len(df.loc[df['P301 attack'] == 1])))
Nombre de données avec attaque sur FIT401 : 104
Nombre de données avec attaque sur LIT301 : 271
Nombre de données avec attaque sur P601 : 230
Nombre de données avec attaque multi point : 449
Nombre de données avec attaque sur MV501 : 119
Nombre de données avec attaque sur P301 : 801
```

Plot des graphiques avec affichages des timezones d'attaques (données décalées)

Nous créons un dossier ou les graphiques décalés seront stockés

```
if not os.path.exists('./bad timezones'):
  os.mkdir('./bad timezones')
folderImg = './bad timezones'
import matplotlib.dates as mdates
deb FIT401 = deb FIT401
fin FIT401 = fin FIT401
deb LIT301 = deb LIT301
fin LIT301 = fin LIT301
deb \ P601 = deb \ P601
fin P601 = fin P601
_deb_MultiPoint = deb MultiPoint
_fin_MultiPoint = fin_MultiPoint
_{deb\_MV501} = deb\_MV501
fin MV501 = fin MV501
deb P301 = deb P301
fin P301 = fin P301
# specify a date to use for the times
zero = pd.datetime(1,1,1)
time = [zero + t for t in df['timestamp']]
deb FIT401 += zero
_fin_FIT401 += zero
_deb_LIT301 += zero
_fin_LIT301 += zero
_deb_P601 += zero
_{fin_{P601}} += zero
_deb_MultiPoint += zero
fin MultiPoint += zero
deb MV501 += zero
fin MV501 += zero
```

```
deb P301 += zero
fin P301 += zero
# convert datetimes to numbers
# Mise en commentaires de cette partie à cause d'erreurs apparaissant
seulement sur Google Colab, sûrement dues à l'utilisation de Python
3.6.9 et non de la version 3.8?
# zero = mdates.date2num(zero)
# time = [t-zero for t in mdates.date2num(time)]
# _deb_FIT401 = mdates.date2num(_deb_FIT401) - zero
# fin FIT401 = mdates.date2num( fin FIT401) - zero
# deb LIT301 = mdates.date2num( deb LIT301) - zero
# fin LIT301 = mdates.date2num(_fin_LIT301) - zero
# deb P601 = mdates.date2num( deb P601) - zero
\# _{fin}P601 = mdates.date2num(_fin_P601) - zero
# deb MultiPoint = mdates.date2num( deb MultiPoint) - zero
# _fin_MultiPoint = mdates.date2num(_fin_MultiPoint) - zero
# deb MV501 = mdates.date2num( deb MV501) - zero
# fin MV501 = mdates.date2num( fin MV501) - zero
# deb P301 = mdates.date2num( deb P301) - zero
# fin P301 = mdates.date2num( fin P301) - zero
print(len(num list))
#add data to plots
for i in range(0,len(num list)):
    fig, axs = plt.subplots()
    axs.title.set text(num list[i])
    axs.plot date(time, df[num list[i]], 'b-')
    axs.axvspan( deb FIT401, fin FIT401, facecolor='pink',alpha=0.5)#
FIT401 atk
    axs.axvspan(_deb_LIT301,_fin_LIT301, facecolor='pink',alpha=0.5)#
LIT301 atk
    axs.axvspan( deb P601, fin P601, facecolor='pink',alpha=0.5)#
P601 atk
    axs.axvspan( deb MultiPoint, fin MultiPoint,
facecolor='pink',alpha=0.5)# Multipoint_atk
    axs.axvspan(_deb_MV501,_fin_MV501, facecolor='pink',alpha=0.5)#
MV501 atk
    axs.axvspan( deb P301, fin P301, facecolor='pink',alpha=0.5)#
P301 atk
    plt.xticks(rotation=-35, ha='left', rotation mode='anchor')
    plt.savefig('./bad timezones/' + num list[i] + '.jpg', dpi=150,
```

```
bbox_inches='tight')
    plt.close(fig)

27

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:21:
FutureWarning: The pandas.datetime class is deprecated and will be removed from pandas in a future version. Import from datetime module instead.
```

Correction des labels avec determination du bon debut et fin de chaque attaque

Les vrais débuts et fins des attaques ont été trouvées à la main

```
# Attaque sur FIT 401
# Debut ligne 9416, fin ligne 9520
real deb FIT401 = timedelta(hours=7, minutes=6, seconds=59)
real fin FIT401 = timedelta(hours=7, minutes=8, seconds=45)
# Attaque sur LIT 301
# Debut ligne 9803, fin ligne 10063
real deb LIT301 = timedelta(hours=7, minutes=13, seconds=26)
real fin LIT301 = timedelta(hours=7, minutes=17, seconds=48)
# Attaque sur P601
# Debut ligne 10509, fin ligne 10738
real deb P601 = timedelta(hours=7, minutes=25, seconds=12)
real fin P601 = timedelta(hours=7, minutes=29, seconds=3)
# Attaque Multi Point
# Debut ligne 11228, fin ligne 11691
real_deb_MultiPoint = timedelta(hours=7, minutes=37, seconds=11)
real fin MultiPoint = timedelta(hours=7, minutes=44, seconds=56)
# Attaque sur MV 501
# Debut ligne 12141, fin ligne 12291
real deb MV501 = timedelta(hours=7, minutes=52, seconds=24)
real fin MV501 = timedelta(hours=7, minutes=54, seconds=56)
# Attaque sur P301
# Debut ligne 12662, fin ligne 13503
real deb P301 = timedelta(hours=8, minutes=1, seconds=5)
real fin P301 = timedelta(hours=8, minutes=15, seconds=8)
On relabelise les données, cette fois ci correctement
cat attack = ['FIT401 attack','LIT301 attack','P601 attack',\
              'MultiPoint attack', 'MV501 attack', 'P301 attack']
```

```
# On transforme chaque colonne XXX attack en colonne de 0
for c in cat attack:
  df[c] = pd.Series(np.zeros(len(df)).astype(int))
# On relabelise
i = 0
for date in df['timestamp']:
    if(date > real deb FIT401 and date < real fin FIT401):</pre>
        df['FIT401_attack'][i] = 1
    if(date > real deb LIT301 and date < real fin LIT301):</pre>
        df['LIT301 attack'][i] = 1
    if(date > real deb P601 and date < real fin P601):</pre>
        df['P601 attack'][i] = 1
    if(date > real_deb_MultiPoint and date < real_fin MultiPoint):</pre>
        df['MultiPoint attack'][i] = 1
    if(date > real deb MV501 and date < real fin MV501):</pre>
        df['MV501 attack'][i] = 1
    if(date > real deb P301 and date < real fin P301):</pre>
        df['P301 attack'][i] = 1
    i += 1
# Pour finir, on change le type de colonnes de int vers object
for c in cat attack:
  df[c] = df[c].astype(str).astype(object)
```

Matrices de correlation

Nous créons un dossier ou les matrices de correlation seront stockées

```
if not os.path.exists('./corrMat'):
    os.mkdir('./corrMat')

folderImg = './corrMat'

pre_attack = df.loc[df['timestamp'] < real_deb_FIT401]

pre_attack_correlation_mat = pre_attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pre_attack_correlation_mat)

img = 'preAttack.png'
plt.title('Correlation Matrix before attacks')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,</pre>
```

```
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
# Pour ne pas afficher directement la matrice de correlation, on fait:
plt.close()
# Matrice de correlation pendant l'attaque sur FIT 401
pdtFit401Attack = df.loc[(df['timestamp'] > real deb FIT401) &\
                         (df['timestamp'] < real fin FIT401)]</pre>
pdtFit401Attack corr = pdtFit401Attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtFit401Attack corr)
img = 'pdtFit401Attack.png'
plt.title('Correlation Matrix during FIT401 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation entre l'attaque sur FIT 401 et LIT 301
entreFit401 Lit301 = df.loc[(df['timestamp'] > real fin FIT401) &\
                            (df['timestamp'] < real deb LIT301)]</pre>
entreFit401 Lit301 corr = entreFit401 Lit301.corr()
plt.figure(figsize=(11,9))
sns.heatmap(entreFit401 Lit301 corr)
ima = 'entreFit401 Lit301.pna'
plt.title('Correlation Matrix between FIT401 attack and LIT301
Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation pendant l'attaque sur LIT 301
pdtLit301Attack = df.loc[(df['timestamp'] > real deb LIT301) &\
                         (df['timestamp'] < real fin LIT301)]</pre>
pdtLit301Attack corr = pdtLit301Attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtLit301Attack corr)
img = 'pdtLit301Attack.png'
```

```
plt.title('Correlation Matrix during LIT301 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation entre l'attaque sur LIT 301 et P601
entreLit301_P601 = df.loc[(df['timestamp'] > real_fin_LIT301) &\
                             (df['timestamp'] < real deb P601)]</pre>
entreLit301 P601 corr = entreLit301 P601.corr()
plt.figure(figsize=(11,9))
sns.heatmap(entreLit301 P601 corr)
img = 'entreLit301 P601.png'
plt.title('Correlation Matrix between Lit301 attack and P601 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation pendant l'attaque sur P601
pdtP601Attack = df.loc[(df['timestamp'] > real_deb_P601) &\
                         (df['timestamp'] < real fin P601)]</pre>
pdtP601Attack corr = pdtP601Attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtP601Attack corr)
img = 'pdtP601Attack.png'
plt.title('Correlation Matrix during P601 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation entre l'attaque sur P601 et l'ataque
MultiPoint
entreP601 Mp = df.loc[(df['timestamp'] > real fin P601) &\
                             (df['timestamp'] < real deb MultiPoint)]</pre>
entreP601_Mp_corr = entreP601_Mp.corr()
plt.figure(figsize=(11,9))
sns.heatmap(entreP601 Mp corr)
```

```
img = 'entreP601 Mp.png'
plt.title('Correlation Matrix between P601 attack and multipoint
Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation pendant l'attaque MultiPoint
pdtMultiPointAttack = df.loc[(df['timestamp'] > real_deb_MultiPoint)
٨\
                          (df['timestamp'] < real fin MultiPoint)]</pre>
pdtMultiPointAttack corr = pdtMultiPointAttack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtMultiPointAttack corr)
img = 'pdtMultiPointAttack.png'
plt.title('Correlation Matrix during Multipoint Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox_inches='tight')
plt.close()
# Matrice de correlation entre l'attaque Multi Point et l'attaque sur
MV501
entreMp MV501 = df.loc[(df['timestamp'] > real fin MultiPoint) &\
                             (df['timestamp'] < real deb MV501)]</pre>
entreMp MV501 corr = entreMp MV501.corr()
plt.figure(figsize=(11,9))
sns.heatmap(entreMp MV501 corr)
img = 'entreMp MV501.png'
plt.title('Correlation Matrix between multipoint attack and MV501
Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation pendant l'attaque MV501
pdtMV501Attack = df.loc[(df['timestamp'] > real deb MV501) &\
```

```
(df['timestamp'] < real fin MV501)]</pre>
pdtMV501Attack corr = pdtMV501Attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtMV501Attack corr)
img = 'pdtMV501Attack.png'
plt.title('Correlation Matrix during MV501 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation entre l'attaque sur MV501 et sur P301
entreMV501 P301 = df.loc[(df['timestamp'] > real_fin_MV501) &\
                             (df['timestamp'] < real deb P301)]</pre>
entreMV501 P301 corr = entreMV501 P301.corr()
plt.figure(figsize=(11,9))
sns.heatmap(entreMV501 P301 corr)
img = 'entreMV501 P301.png'
plt.title('Correlation Matrix between MV501 and P301 Attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation pendant l'attaque sur P301
pdtP301Attack = df.loc[(df['timestamp'] > real deb P301) &\
                          (df['timestamp'] < real fin P301)]</pre>
pdtP301Attack corr = pdtP301Attack.corr()
plt.figure(figsize=(11,9))
sns.heatmap(pdtP301Attack corr)
img = 'pdtP301Attack.png'
plt.title('Correlation Matrix during P301 Attack')
plt.xlabel('')
plt.vlabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
```

```
# Matrice de correlation apres toutes les attaques
apresAttack = df.loc[df['timestamp']> real fin P301]
apresAttack corr = apresAttack.corr()
plt.figure(figsize=(11,9))
sns plot=sns.heatmap(apresAttack corr)
img = 'apresAttack.png'
plt.title('Correlation Matrix after all attack')
plt.xlabel('')
plt.ylabel('')
plt.savefig(os.path.join(folderImg,
img), facecolor='lightgrey', edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
# Matrice de correlation, toutes les données avec les labels
d'attaques
bla = df.copy()
bla['FIT401 attack'] = bla['FIT401 attack'].astype(float)
bla['LIT301_attack'] = bla['LIT301_attack'].astype(float)
bla['P601 attack'] = bla['P601 attack'].astype(float)
bla['MultiPoint attack'] = bla['MultiPoint attack'].astype(float)
bla['MV501 attack'] = bla['MV501 attack'].astype(float)
bla['P301 attack'] = bla['P301 attack'].astype(float)
print(bla['FIT401 attack'].dtypes)
bla corr = bla.corr()
plt.figure(figsize=(11,9))
sns.heatmap(bla corr)
img = 'toutesDonnesAvecLabel.png'
plt.title('Correlation Matrix on all datas and on attacks ')
plt.xlabel('')
plt.vlabel('')
plt.savefig(os.path.join(folderImg,
img),facecolor='lightgrey',edgecolor='black',
transparent=False,bbox inches='tight')
plt.close()
float64
```

Plot des graphiques avec affichages des timezones d'attaques (données correctes)

Nous créons un dossier ou les bonnes timezones seront stockées

```
if not os.path.exists('./good timezones'):
  os.mkdir('./good timezones')
folderImg = './good timezones'
deb FIT401 = real deb FIT401
fin FIT401 = real fin FIT401
_deb_LIT301 = real_deb_LIT301
fin LIT301 = real fin LIT301
_{deb}_{P601} = real_{deb}_{P601}
fin P601 = real fin P601
_deb_MultiPoint = real_deb_MultiPoint
_fin_MultiPoint = real_fin_MultiPoint
deb MV501 = real deb MV501
fin MV501 = real fin MV501
_{deb}_{P301} = real_{deb}_{P301}
fin P301 = real fin P301
# specify a date to use for the times
zero = pd.datetime(1,1,1)
time = [zero + t for t in df['timestamp']]
deb FIT401 += zero
fin FIT401 += zero
_deb_LIT301 += zero
fin LIT301 += zero
_deb_P601 += zero
fin P601 += zero
deb MultiPoint += zero
_fin_MultiPoint += zero
deb MV501 += zero
fin MV501 += zero
```

```
_deb_P301 += zero
fin P301 += zero
# convert datetimes to numbers
# Mise en commentaires de cette partie à cause d'erreurs apparaissant
seulement sur Google Colab, sûrement dues à l'utilisation de Python
3.6.9 et non de la version 3.8?
# zero = mdates.date2num(zero)
# time = [t-zero for t in mdates.date2num(time)]
# deb FIT401 = mdates.date2num( deb FIT401) - zero
# fin FIT401 = mdates.date2num( fin FIT401) - zero
# deb LIT301 = mdates.date2num( deb LIT301) - zero
# fin LIT301 = mdates.date2num( fin LIT301) - zero
\# \_deb\_P601 = mdates.date2num(\_deb\_P601) - zero
# fin P601 = mdates.date2num( fin P601) - zero
# deb MultiPoint = mdates.date2num( deb MultiPoint) - zero
# fin MultiPoint = mdates.date2num( fin MultiPoint) - zero
# deb MV501 = mdates.date2num( deb MV501) - zero
# fin MV501 = mdates.date2num( fin MV501) - zero
# deb P301 = mdates.date2num( deb P301) - zero
# fin P301 = mdates.date2num( fin P301) - zero
#add data to plots
print(len(num list))
for i in range(0,len(num list)):
    fig, axs = plt.subplots()
    axs.title.set text(num list[i])
    axs.plot date(time, df[num list[i]], 'b-')
    axs.axvspan(_deb_FIT401,_fin_FIT401, facecolor='pink',alpha=0.5)#
FIT401 atk
    axs.axvspan( deb LIT301, fin LIT301, facecolor='pink',alpha=0.5)#
LIT301 atk
    axs.axvspan( deb P601, fin P601, facecolor='pink',alpha=0.5)#
P601 atk
    axs.axvspan( deb MultiPoint, fin MultiPoint,
facecolor='pink',alpha=0.5)# Multipoint atk
    axs.axvspan( deb MV501, fin MV501, facecolor='pink',alpha=0.5)#
MV501 atk
    axs.axvspan( deb P301, fin P301, facecolor='pink',alpha=0.5)#
P301 atk
    plt.xticks(rotation=-35, ha='left', rotation_mode='anchor')
    plt.savefig('./good timezones/' + num list[i] + '.jpg', dpi=150,
```

```
bbox_inches='tight')
    plt.close(fig)
```

Algorithmes de detection d'anomalies

- Isolation Forest

On ajoute une colonne isAttack qui servira de label pour généraliser les attaques. Si lors de l'observation, le systeme est attaqué (FIT401, LIT301 etc.), isAttack sera à 1, 0 sinon.

```
df['isAttack'] = ((df['FIT401 attack']=='1') |
(df['LIT301 attack']=='1') | \
                  (df['P601 attack']=='1') |
(df['MultiPoint attack']=='\overline{1}') |\
                  (df['MV501 attack']=='1') |
(df['P301 attack']=='1'))
df['isAttack'] = df['isAttack'].replace({True:1, False:0})
df['isAttack'] = df['isAttack'].astype(str).astype(object)
# On définit X et Y qu'on utilisera pour fit le classifieur
X =
df.drop(['timestamp','FIT401 attack','LIT301 attack','P601 attack','Mu
ltiPoint attack',\
              'MV501 attack', 'P301 attack', 'isAttack'], axis=1)
Y = df[['isAttack']]
# On replace tous les espaces dans les noms des colonnes par des ' '
X.rename(columns = lambda x: x.replace(' ', '_'), inplace=True)
# On one-hot toutes les colonnes catégoriques de X
cat list X = X.select dtypes(include=['object'])
for i in cat list X:
  oneHotEnc = pd.qet dummies(X[i], prefix=i)
  X = pd.concat([X, oneHotEnc], axis=1)
 X = X.drop(i, axis=1)
Definition des paramètres du modèle
from sklearn.ensemble import IsolationForest
rng = np.random.RandomState(99)
#Dans le jeu de données, on a 2053 observations qui sont labélisées 1
sur
#'isAttack' et en tout nous avons 14996 observations donc ça fait
#13.69032% de outliers
outlier fraction=0.1369
nb samples = len(df)
```

```
clf = IsolationForest(max samples = nb samples,
contamination=outlier fraction,\
                      random state=rng)
Entrainement et prédiction du modèle
clf.fit(X)
ifOutliers = clf.predict(X)
Evaluation de l'éfficacité d'isolation forest
from sklearn.metrics import average precision score
from sklearn.metrics import precision recall curve
from sklearn.metrics import roc_curve, auc
compTab = Y.copy()
compTab['ifOutliers'] = ifOutliers
nbAnomalies = len(compTab.loc[compTab['isAttack']=='1'])
nbTruePos = len(compTab.loc[(compTab['isAttack']=='1') &\
                             (compTab['ifOutliers']==-1)])
print("Le nombre d'anomalies au total est: " + str(nbAnomalies)+"\n")
print("Le nombre de vrais positifs est: " + str(nbTruePos)+ "\n")
print("Le taux de detections correctes est de: " + \
      str(nbTruePos*100/nbAnomalies) +"%\n")
#AUPRC (Area Under the Precision-Recall Curve)
#print([int(label) for label in RFOutliers ], y test)
print('AUPRC =
{}'.format(average precision score(y true=compTab['isAttack'],\
y score=compTab['ifOutliers'],\
                                                 pos label='1')))
precision, recall, thresholds =
precision recall curve(compTab['isAttack'],\
compTab['ifOutliers'],\
                                                       pos label='1')
plt.figure(figsize=(9,7))
plt.title("AUPRC isolation forest")
plt.plot(recall, precision, lw=2.0)
#ROC (Receiver Operating Characteristic)
fpr, tpr, thresholds = roc curve(compTab['isAttack'],
compTab['ifOutliers'] , pos label='1')
roc auc = auc(fpr, tpr)
# plt.figure(figsize=(9,7))
# plt.plot(fpr, tpr, lw=2.0)
plt.figure(figsize=(10,7))
plt.plot(fpr, tpr, color='darkorange', lw=lw)
plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
plt.xlim([-0.02, 1.0])
```

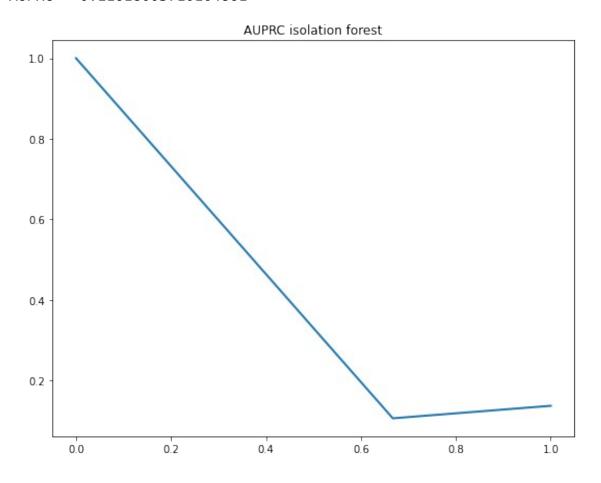
```
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC curve isolation forest')
plt.show()
```

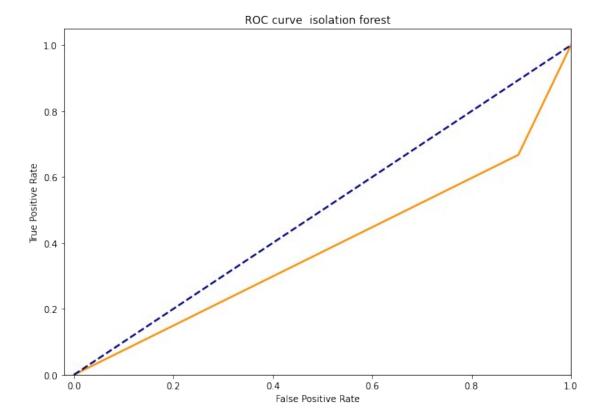
Le nombre d'anomalies au total est: 2053

Le nombre de vrais positifs est: 683

Le taux de detections correctes est de: 33.26838772528008%

AUPRC = 0.11618003710104861





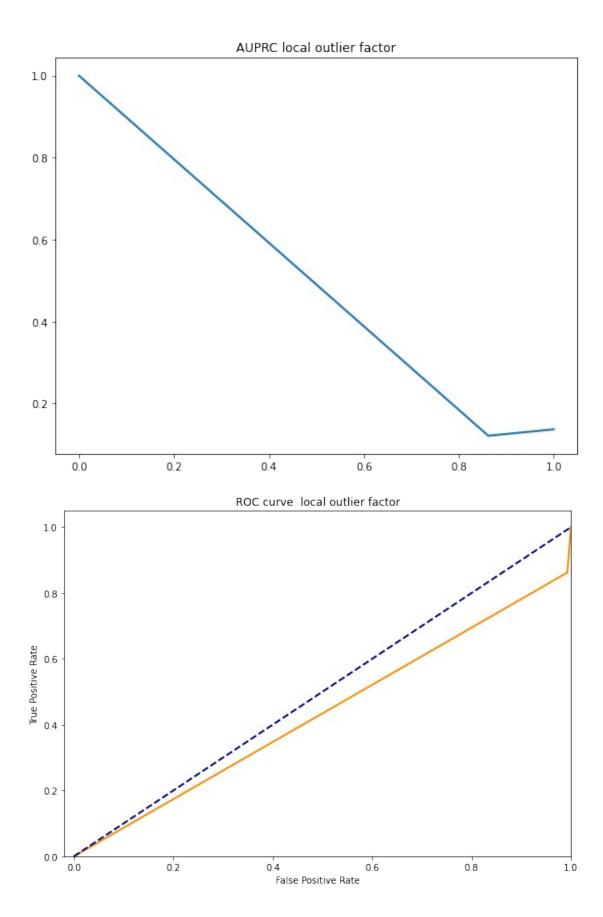
Local Outlier Factor (LOF)

Definition des paramètres du modèle

from sklearn.neighbors import LocalOutlierFactor

```
# On peut faire varier n neighbors pour obtenir des taux de detection
# differents, pour 5000 le taux de detection etait le plus elevé
clf = LocalOutlierFactor(n neighbors=5000)
Entrainement et prédiction du modèle
lofOutliers = clf.fit predict(X)
Evaluation de l'éfficacité de Local Outlier Factor
compTab['lofOutliers'] = lofOutliers
nbTruePos = len(compTab.loc[(compTab['isAttack']=='1') &\
                             (compTab['lofOutliers']==-1)])
print("Le nombre d'anomalies au total est: " + str(nbAnomalies)+"\n")
print("Le nombre de vrais positifs est: " + str(nbTruePos)+ "\n")
print("Le taux de detections correctes est de: " + \
      str(nbTruePos*100/nbAnomalies) +"%\n")
#AUPRC (Area Under the Precision-Recall Curve)
print('AUPRC =
{}'.format(average precision score(y true=compTab['isAttack'],\
```

```
y score=compTab['lofOutliers'],\
                                                pos label='1')))
precision, recall, thresholds =
precision recall curve(compTab['isAttack'],\
compTab['lofOutliers'],\
                                                      pos label='1')
plt.figure(figsize=(9,7))
plt.title("AUPRC local outlier factor")
plt.plot(recall, precision, lw=2.0)
#ROC (Receiver Operating Characteristic)
fpr, tpr, thresholds = roc_curve(compTab['isAttack'],
compTab['lofOutliers'] , pos_label='1')
roc auc = auc(fpr, tpr)
plt.figure(figsize=(10,7))
lw = 2
plt.plot(fpr, tpr, color='darkorange', lw=lw)
plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
plt.xlim([-0.02, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC curve local outlier factor')
plt.show()
Le nombre d'anomalies au total est: 2053
Le nombre de vrais positifs est: 283
Le taux de detections correctes est de: 13.784705309303458%
AUPRC = 0.12324999706951417
```

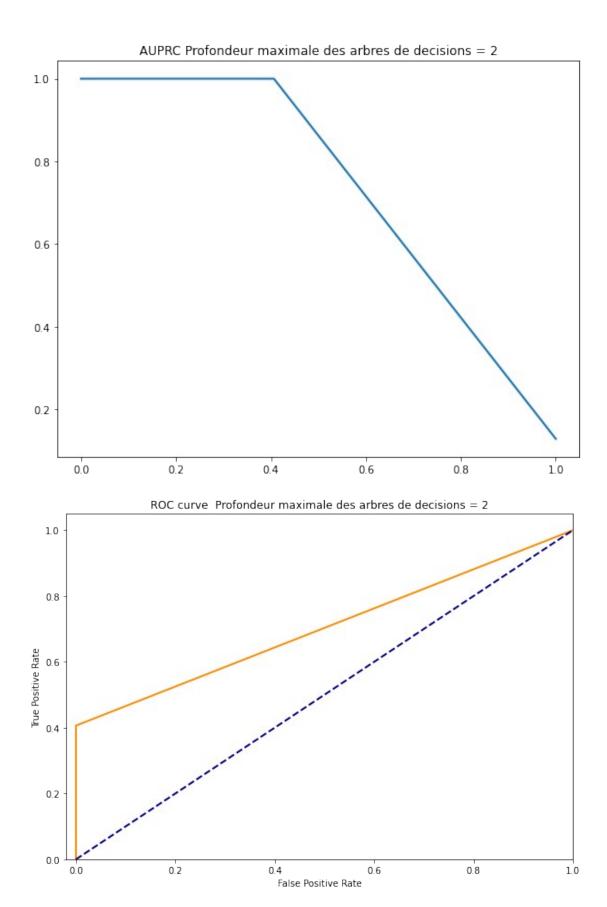


Random Forest

On modifie la profondeur maximale des arbres de decisions.

```
from sklearn.model selection import train test split
from sklearn.ensemble import RandomForestClassifier
X train, X test, y train, y test = train test split(X, Y, test size =
0.2,\
                                                    random state=5)
for i in range(2, 6):
      clf = RandomForestClassifier(max depth=i, random state=0)
      clf.fit(X train, y train)
      RFOutliers = clf.predict(X test)
      compTab = y_test.copy()
      compTab['RFOutliers'] = RFOutliers
      nbAnomaliesTest = len(y test.loc[y test['isAttack']=='1'])
      nbTruePos = len(compTab.loc[(compTab['isAttack']=='1') &\
                              (compTab['RFOutliers']=='1')])
      print("---- Profondeur maximale des arbres de decisions = " +
str(i) + " ----")
      print("Le nombre d'anomalies au total est: " +
str(nbAnomaliesTest)+"\n")
      print("Le nombre de vrais positifs est: " + str(nbTruePos)+ "\
n")
      print("Le taux de detections correctes est de: " + \
            str(nbTruePos*100/nbAnomaliesTest) +"%\n")
      print("Le score est de: " + \
            str(clf.score(X test, y test)))
      #AUPRC (Area Under the Precision-Recall Curve)
      print('AUPRC =
{}'.format(average precision score(y true=y test,\
y score=[int(label) for label in RFOutliers ],\
                                                      pos label='1')))
      precision, recall, thresholds = precision recall curve(y test,\)
[int(label) for label in RFOutliers ],\
pos_label='1')
      print('ROC = ' + str(roc_auc))
      plt.figure(figsize=(9,7))
      plt.title("AUPRC Profondeur maximale des arbres de decisions = "
```

```
+ str(i))
      plt.plot(recall, precision, lw=2.0)
      #ROC (Receiver Operating Characteristic)
      fpr, tpr, thresholds = roc curve(y test, [int(label) for label
in RFOutliers ] , pos label='1')
      roc auc = auc(fpr, tpr)
      # plt.figure(figsize=(9,7))
      # plt.plot(fpr, tpr, lw=2.0)
      plt.figure(figsize=(10,7))
      lw = 2
      plt.plot(fpr, tpr, color='darkorange', lw=lw)
      plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
      plt.xlim([-0.02, 1.0])
      plt.ylim([0.0, 1.05])
      plt.xlabel('False Positive Rate')
      plt.ylabel('True Positive Rate')
      plt.title('ROC curve Profondeur maximale des arbres de
decisions = ' + str(i))
      plt.show()
/usr/local/lib/python3.7/dist-packages/ipykernel launcher.py:8:
DataConversionWarning:
A column-vector y was passed when a 1d array was expected. Please
change the shape of y to (n samples,), for example using ravel().
----- Profondeur maximale des arbres de decisions = 2 -----
Le nombre d'anomalies au total est: 384
Le nombre de vrais positifs est: 156
Le taux de detections correctes est de: 40.625%
Le score est de: 0.924
AUPRC = 0.48225
ROC = 0.999987058804791
```



/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:8:
DataConversionWarning:

A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n_samples,), for example using ravel().

----- Profondeur maximale des arbres de decisions = 3 -----Le nombre d'anomalies au total est: 384

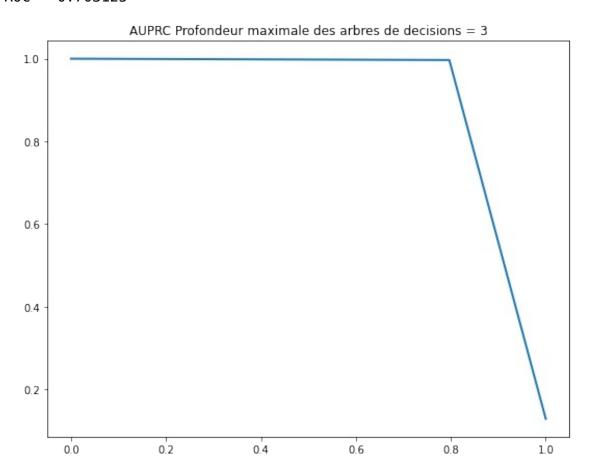
Le nombre de vrais positifs est: 306

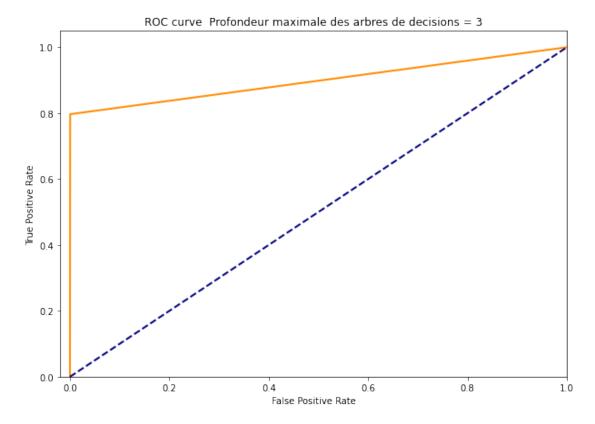
Le taux de detections correctes est de: 79.6875%

Le score est de: 0.973666666666667

AUPRC = 0.8202793159609121

ROC = 0.703125





/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:8:
DataConversionWarning:

A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n samples,), for example using ravel().

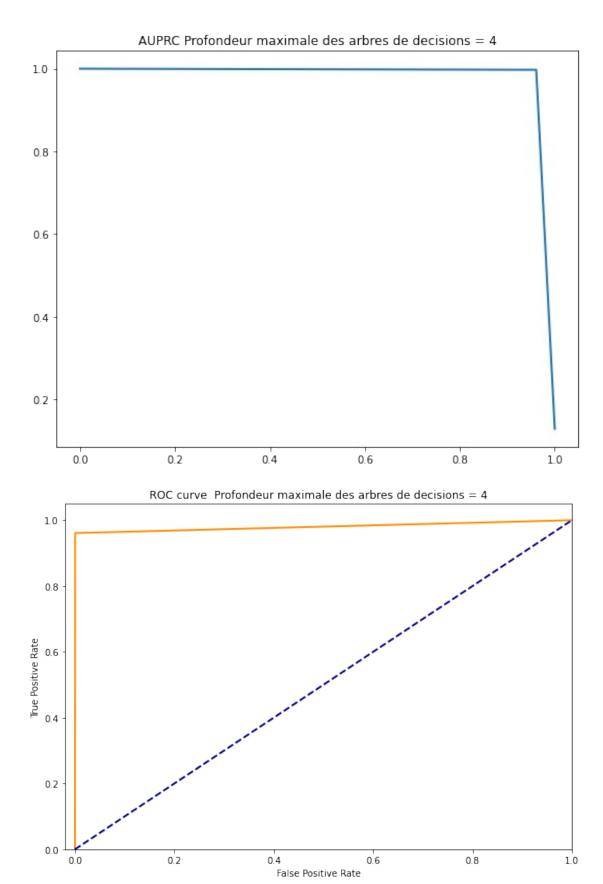
----- Profondeur maximale des arbres de decisions = 4 -----Le nombre d'anomalies au total est: 384

Le nombre de vrais positifs est: 369

Le taux de detections correctes est de: 96.09375%

Le score est de: 0.994666666666667

AUPRC = 0.9633403716216217 ROC = 0.8982463685015291



/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:8:
DataConversionWarning:

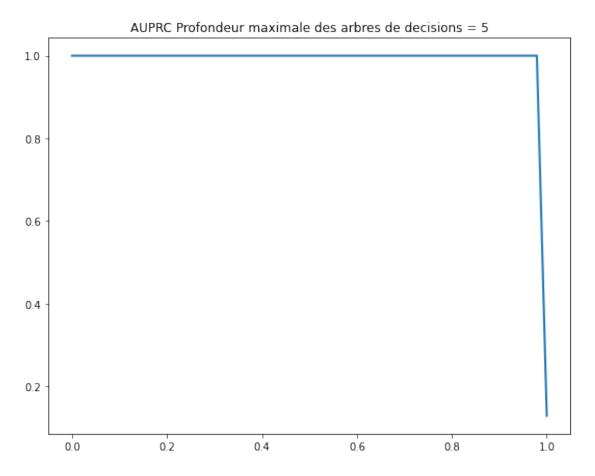
A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n_samples,), for example using ravel().

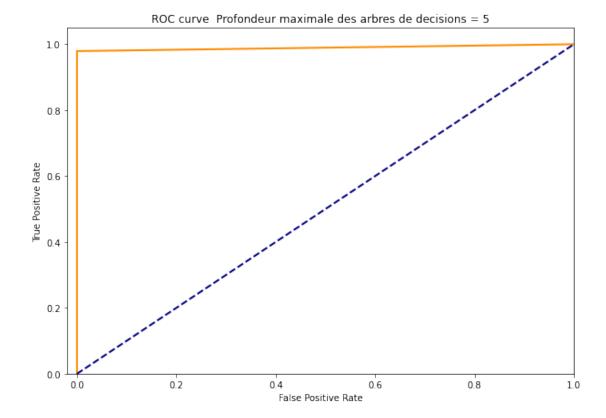
---- Profondeur maximale des arbres de decisions = 5 -----Le nombre d'anomalies au total est: 384

Le nombre de vrais positifs est: 376

Le taux de detections correctes est de: 97.916666666666667%

Le score est de: 0.99733333333333333





XGBoost

Préparation des données

from sklearn.model selection import train test split

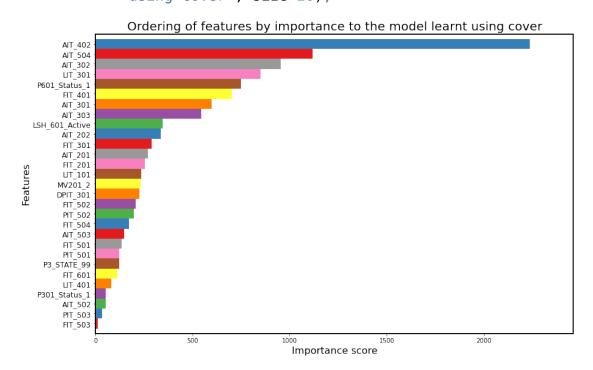
Définition des paramétres du modèle

On ajoute un poids pour équilibrer les données car dans notre jeu de donnés nous avons 2053 observations qui ont isAttack=1 et 12943 observations qui ont isAttack = 0.

```
from xgboost import XGBClassifier
# nbr d'observations non attaque divisé par le nombre d'observations
lors d'une attaque
weights = (Y['isAttack']=='0').sum() / (1.0 *
(Y['isAttack']=='1').sum())
clf = XGBClassifier(max_depth = 3, scale_pos_weight=weights, n_jobs = 4)
xgbTestOutliers = clf.fit(X_train,y_train).predict(X_test)
probabilities = clf.predict_proba(X_test)
/usr/local/lib/python3.7/dist-packages/sklearn/preprocessing/
label.py:235: DataConversionWarning: A column-vector y was passed
```

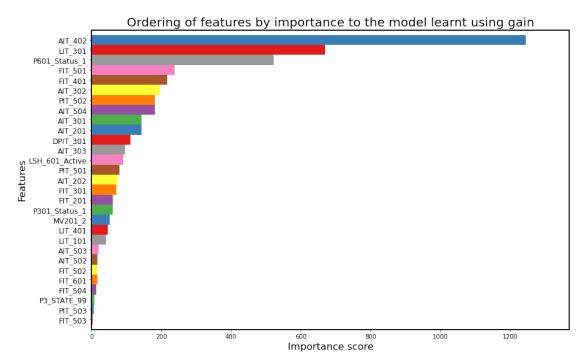
```
when a 1d array was expected. Please change the shape of v to
(n samples, ), for example using ravel().
  y = column_or_ld(y, warn=True)
/usr/local/lib/python3.7/dist-packages/sklearn/preprocessing/ label.py
:268: DataConversionWarning: A column-vector y was passed when a 1d
array was expected. Please change the shape of y to (n samples, ), for
example using ravel().
  y = column or 1d(y, warn=True)
Evaluation de l'éfficacité d'xgboost
compTab2 = y test.copy()
compTab2['xgbTestOutliers'] = xgbTestOutliers
nbElts = len(y test)
nbAnomaliesTest = len(y_test.loc[y_test['isAttack']=='1'])
nbTruePos = len(compTab2.loc[(compTab2['isAttack']=='1') &\
                             (compTab2['xqbTestOutliers']=='1')])
print("Le nombre d'elements dans y test est: " + str(nbElts) +"\n")
print("Le nombre d'anomalies dans y_test est: " + str(nbAnomaliesTest)
+ "\n")
print("Le nombre d'anomalies detectées par XGBoost: " + str(nbTruePos)
+ "\n")
Le nombre d'elements dans y test est: 3000
Le nombre d'anomalies dans y test est: 384
Le nombre d'anomalies detectées par XGBoost: 382
print("Pourcentage d'anomalies détectées par XGBoost par rapport au
nombre réel d'anomalie : " + str((nbTruePos/nbAnomaliesTest)*100) +
"%")
Pourcentage d'anomalies détectées par XGBoost par rapport au nombre
réel d'anomalie : 99.479166666666666
Visualisation des resultats et interpretation
Cover
from xgboost import plot importance, plot tree
# Affichage de l'importance des colonnes selon le cover
fig = plt.figure(figsize=(14,9))
ax = fig.add subplot(111)
colours = plt.cm.Set1(np.linspace(0,1,9))
ax = plot importance(clf, height=1, color=colours, grid=False, \
```

show values=False, importance type='cover',

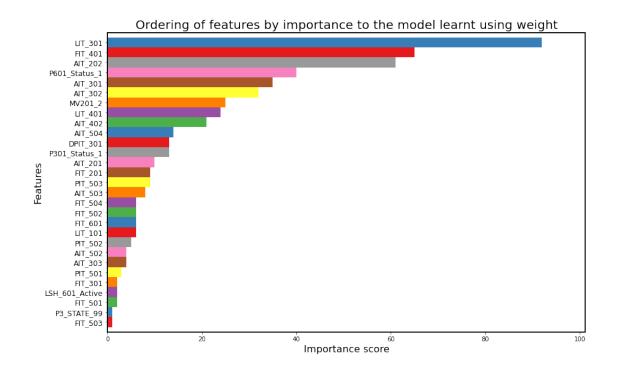


Gain

```
'using gain', size=20);
```

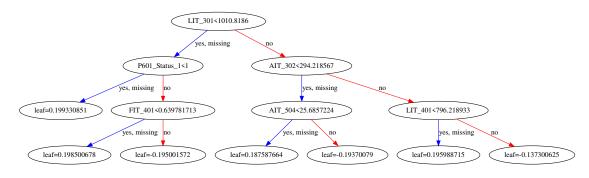


Weight



Arbre du classifieur

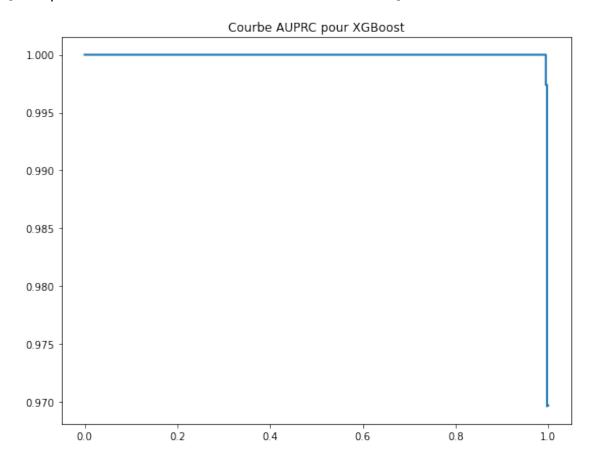
from xgboost import to_graphviz
to graphviz(clf)



```
pos_label='1')
```

```
plt.figure(figsize=(9,7))
plt.title('Courbe AUPRC pour XGBoost')
plt.plot(recall, precision, lw=2.0)
AUPRC = 0.9999143041745581
```

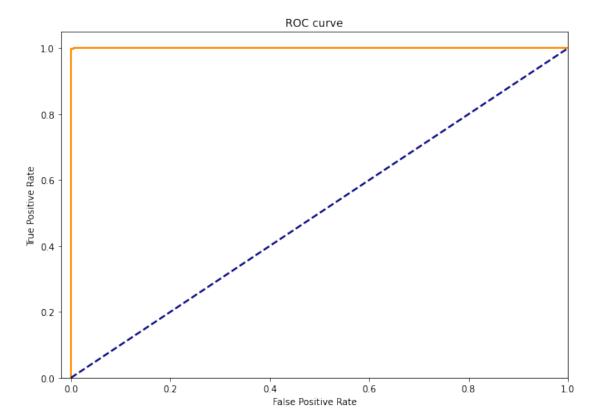
[<matplotlib.lines.Line2D at 0x7f1d8b7a0c50>]



Courbe ROC

```
#ROC (Receiver Operating Characteristic)
from sklearn.metrics import roc_curve, auc
fpr, tpr, thresholds = roc_curve(y_test, probabilities[:,1],
pos_label='1')
roc_auc = auc(fpr, tpr)
# plt.figure(figsize=(9,7))
# plt.plot(fpr, tpr, lw=2.0)
plt.figure(figsize=(10,7))
lw = 2
```

```
plt.plot(fpr, tpr, color='darkorange', lw=lw)
plt.plot([0, 1], [0, 1], color='navy', lw=lw, linestyle='--')
plt.xlim([-0.02, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC curve')
plt.show()
```



Interpretations

D'après ces résultats, nous pouvons conclure que l'attribut qui influence le plus grand nombre de prédictions (cover) est AIT 402 qui correspond à l'analyseur de NaHSO3 et de NaOCl dans la partie P4 du système de traitement.

L'attribut le plus important et le plus discriminant (gain) pour les prédictions est aussi AIT 402.

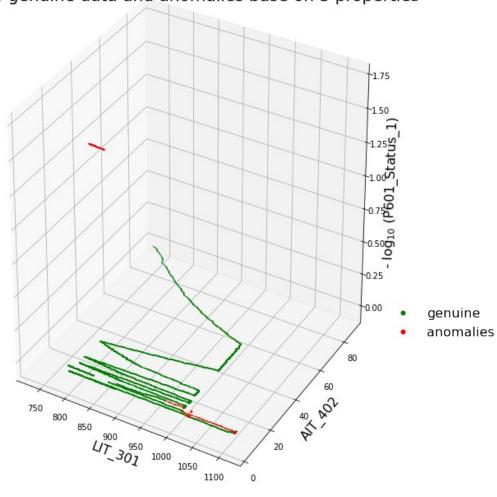
L'attribut qui est utilisé dans le plus grand nombre de splits dans les arbres de décision créés par XGBoost (weight) est LIT 301, qui correspond au détecteur de niveau d'eau dans le UF feed tank de la partie P3 du système de traitement.

Donc pour améliorer la sécurité du système, il faudrait idéalement regarder de plus près et avec plus de soin les attributs AIT 402 et LIT 301.

Plot des données en 3D

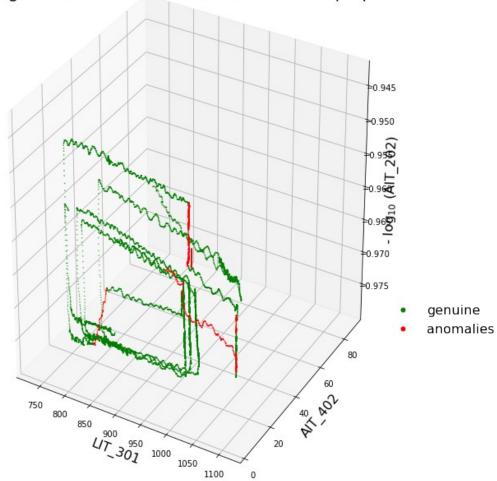
```
import matplotlib.lines as mlines
def show3D_data(X, Y, x_axis_name, y_axis_name, z_axis_name):
  x=x axis name
  v=v axis name
  z=z_axis_name
  z0ffset = 0.02
  limit=len(X)
  sns.reset orig()
  fig = plt.figure(figsize=(10,12))
  ax = fig.add subplot(111,projection='3d')
  ax.scatter(X.loc[Y['isAttack']=='0',x][:limit],\
             X.loc[Y['isAttack']=='0',y][:limit], \
             -np.log10(X.loc[Y['isAttack']=='0',z][:limit]+z0ffset),\
             c='g', marker='.', s=1, label='genuine')
  ax.scatter(X.loc[Y['isAttack']=='1',x][:limit],\
             X.loc[Y['isAttack']=='1',y][:limit],\
             -np.log10(X.loc[Y['isAttack']=='1',z][:limit] +
z0ffset),\
             c='r', marker='.', s=1, label='anomalies')
  ax.set xlabel(x,size=16);
  ax.set_ylabel(y, size=16);
  ax.set_zlabel('- log$ {10}$ (' +z+ ')', size=16)
  ax.set title('Plot of genuine data and anomalies base on 3
properties',\
               size=20)
  plt.axis('tight')
  ax.grid(1)
  noAnomalyMaker = mlines.Line2D([], [], linewidth=0, color='g',
marker='.',\
                               markersize=10, label='genuine')
  anomalyMaker = mlines.Line2D([], [], linewidth=0, color='r',
marker='.',\
                             markersize=10, label='anomalies')
  plt.legend(handles=[noAnomalyMaker, anomalyMaker], \
             bbox to anchor=(1.20, 0.38), frameon=False,
prop={'size':16});
show3D data(X,Y,'LIT 301','AIT 402', 'P601 Status 1')
```

Plot of genuine data and anomalies base on 3 properties



Plot d'autres attributs importants
show3D_data(X,Y,'LIT_301','AIT_402', 'AIT_202')

Plot of genuine data and anomalies base on 3 properties



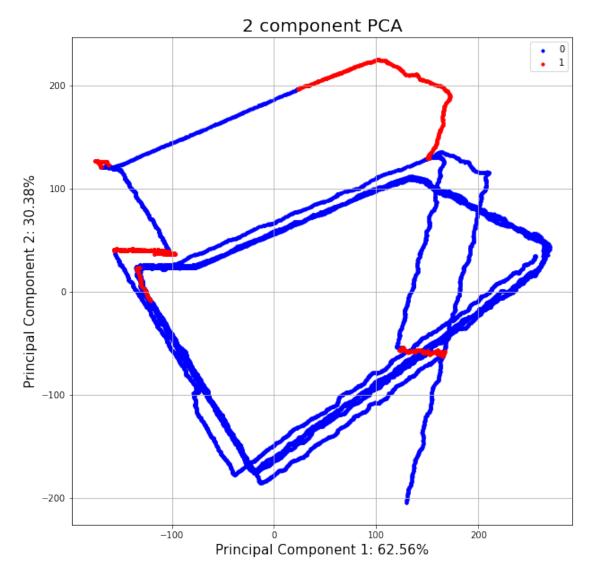
PCA

On crée un nouveau dataframe qui differencie les differentes attaques pour l'affichage.

```
new_y = pd.DataFrame(columns=['is_attack_detail'])

for i in range(len(df)):
    if (df.at[i,'FIT401_attack'] == '1'):
        new_row = {'is_attack_detail':'1'}
        new_y = new_y.append(new_row, ignore_index=True)
    elif (df.at[i,'LIT301_attack'] == '1'):
        new_row = {'is_attack_detail':'2'}
        new_y = new_y.append(new_row, ignore_index=True)
    elif (df.at[i,'P601_attack'] == '1'):
        new_row = {'is_attack_detail':'3'}
        new_y = new_y.append(new_row, ignore_index=True)
```

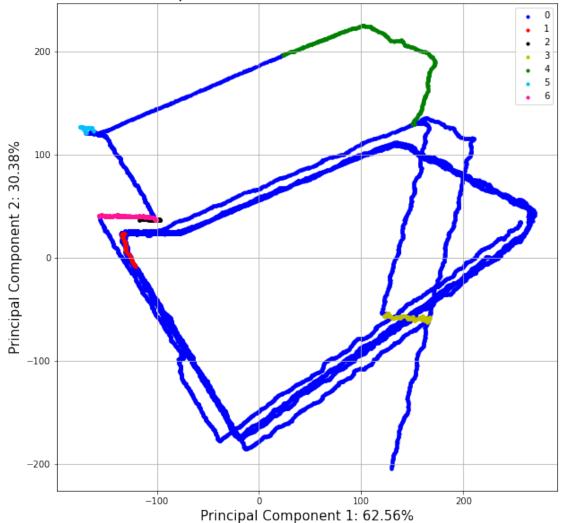
```
elif (df.at[i,'MultiPoint attack'] == '1'):
        new_row = {'is_attack_detail':'4'}
        new y = new y.append(new row, ignore index=True)
    elif (df.at[i,'MV501 attack'] == '1'):
        new row = {'is attack detail':'5'}
        new_y = new_y.append(new_row, ignore_index=True)
    elif (d\bar{f},at[i,'P301 attack'] == '1'):
        new row = {'is attack detail':'6'}
        new y = new y.append(new row, ignore index=True)
    else:
        new row = {'is attack detail':'0'}
        new_y = new_y.append(new_row, ignore index=True)
from sklearn.decomposition import PCA
pca = PCA(n components = 2)
pca bis = pca.fit(X)
principal_components = pca.fit transform(X)
principalDf = pd.DataFrame(data = principal components, columns =
['principal component 1', 'principal component 2'])
finalDf = pd.concat([principalDf, Y], axis = 1)
finalDf = pd.concat([finalDf, new y], axis = 1)
finalDf.head()
   principal component 1 principal component 2 isAttack
is attack detail
              129.264241
                                     -204.826144
                                                         0
0
1
              129.530638
                                     -204.452694
                                                         0
0
2
              129.180631
                                     -203.004077
                                                         0
0
3
              129.624511
                                     -202.490752
                                                         0
0
4
              130.275124
                                     -202.057385
                                                         0
On affiche les données sur le plan de l'ACP en les différenciant selon 2 possibilités (attaque
ou non)
fig = plt.figure(figsize = (10,10))
ax = fig.add subplot(1,1,1)
ax.set xlabel('Principal Component 1:
'+"{:.2f}".format(pca bis.explained variance ratio [0]*100)+'%',
fontsize = 15)
ax.set ylabel('Principal Component 2:
'+"{:.2f}".format(pca bis.explained variance ratio [1]*100)+'%',
```



Ici on affiche les 6 attaques d'une couleur différente

```
fig = plt.figure(figsize = (10,10))
ax = fig.add_subplot(1,1,1)
ax.set xlabel('Principal Component 1:
```

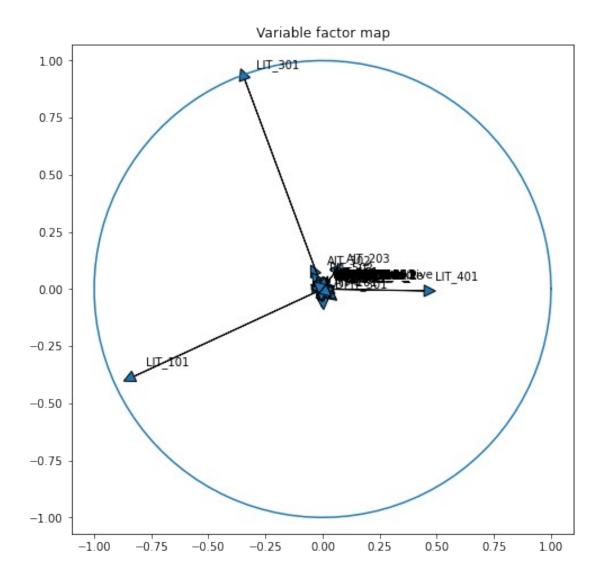




```
print(pca_bis.explained_variance_ratio_)
print(str(round(pca_bis.explained_variance_ratio_.sum() * 100, 2)) + '
%')
[0.62560855 0.30382306]
92.94 %
```

On voit que les 2 premières composantes principales gardent 92,94% de l'information ce qui nous semble correcte.

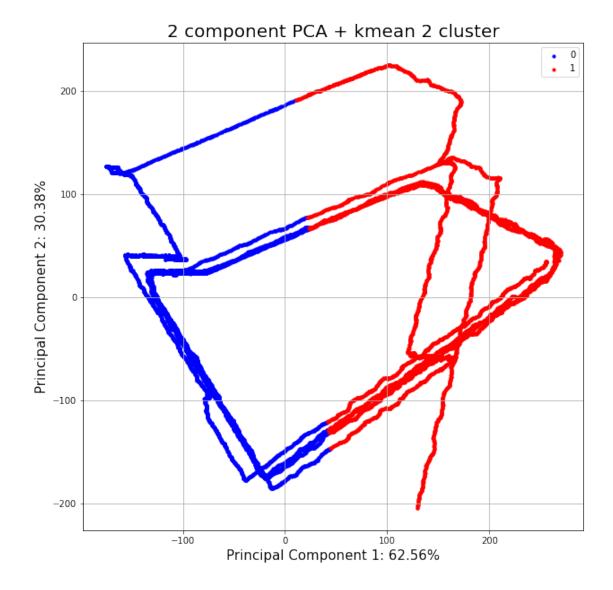
Cercle de correlation



KMeans (2 clusters)

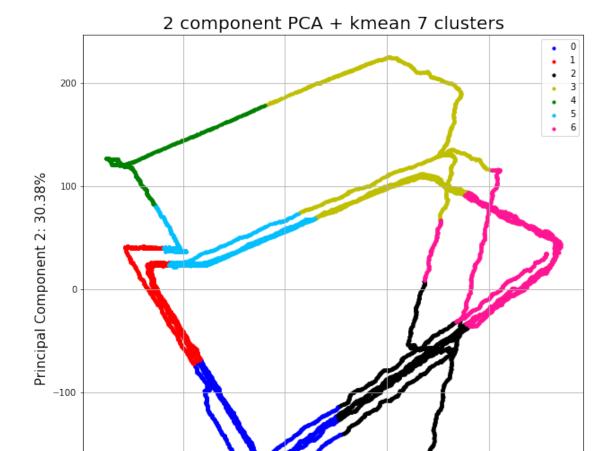
```
from sklearn.cluster import KMeans
```

```
print("Le nombre d'anomalies detectées par Kmeans: " + str(nbTruePos)
+ "\n")
Le nombre d'élements dans Y est: 14996
Le nombre d'anomalies dans Y est: 2053
Le nombre d'anomalies detectées par Kmeans: 0
finalDf['Kmeans 2 cluster'] = kmeans.labels .tolist()
finalDf.head()
   principal component 1
                               Kmeans_2_cluster
0
              129.264241
                                               1
              129.530638
                                               1
1
                          . . .
2
              129.180631
                                               1
3
              129.624511
                                               1
              130.275124 ...
4
                                               1
[5 rows x 5 columns]
fig = plt.figure(figsize = (10,10))
ax = fig.add subplot(1,1,1)
ax.set xlabe ('Principal Component 1:
'+"{:.2f}".format(pca bis.explained variance ratio [0]*100)+'%',
fontsize = 15)
ax.set ylabel('Principal Component 2:
'+"{:.2f}".format(pca bis.explained variance ratio [1]*100)+'%',
fontsize = 15)
ax.set title('2 component PCA + kmean 2 cluster', fontsize = 20)
labels = [0, 1]
colors = ['b', 'r']
for target, color in zip(labels,colors):
    indicesToKeep = finalDf['Kmeans 2 cluster'] == target
    ax.scatter(finalDf.loc[indicesToKeep, 'principal component 1']
               , finalDf.loc[indicesToKeep, 'principal component 2']
               , c = color
               s = 10
ax.legend(labels)
ax.grid()
```



KMeans (7 clusters)

```
129.624511 ...
3
                                              2
4
              130.275124 ...
[5 rows x 6 columns]
fig = plt.figure(figsize = (10,10))
ax = fig.add subplot(1,1,1)
ax.set xlabe ('Principal Component 1:
'+"{:.2f}".format(pca_bis.explained_variance_ratio_[0]*100)+'%',
fontsize = 15)
ax.set ylabel('Principal Component 2:
'+"{:.2f}".format(pca_bis.explained_variance_ratio_[1]*100)+'%',
fontsize = 15)
ax.set title('2 component PCA + kmean 7 clusters', fontsize = 20)
labels = [0, 1, 2, 3, 4, 5, 6]
colors = ['b', 'r', 'black', 'y', 'g', 'deepskyblue', 'deeppink']
for target, color in zip(labels,colors):
    indicesToKeep = finalDf['Kmeans 7 cluster'] == target
    ax.scatter(finalDf.loc[indicesToKeep, 'principal component 1']
               , finalDf.loc[indicesToKeep, 'principal component 2']
               , c = color
               , s = 10)
ax.legend(labels)
ax.grid()
```



Principal Component 1: 62.56%

200

LSTM

-200

-100

```
import plotly.express as px # to plot the time series plot
from sklearn import metrics # for the evaluation
from sklearn.preprocessing import LabelEncoder,MinMaxScaler
import tensorflow as tf

data = X.copy()

for i in data.select_dtypes('object').columns:
    le = LabelEncoder().fit(data[i])
    data[i] = le.transform(data[i])

X_scaler = MinMaxScaler()
Y_scaler = MinMaxScaler()
```

```
X data = X scaler.fit transform(data)
Y_data = Y_scaler.fit_transform(Y)
def make data for lstm(dataset, target, window, horizon, nb train, n):
    # nb_test represente le nombre de données qui seront dans le jeu
d'entrainement sur n données
    # il y aura donc n - nb train dans le jeu de test sur ces n
données
    X train = []
    y train = []
    X \text{ test} = []
    y_test = []
    cpt = 0
    for i in range(window, len(dataset)-window):
        indices = range(i-window, i)
        indicey = range(i+1, i+1+horizon)
        if (cpt < nb train):</pre>
            X train.append(dataset[indices])
            y train.append(target[indicey])
        else:
            X test.append(dataset[indices])
            y_test.append(target[indicey])
        cpt += 1
        if (cpt >= n):
            cpt = 0
    return np.array(X train), np.array(X_test), np.array(y_train),
np.array(y test)
hist window = 30
horizon = 5
nb train = 8
n = 10
X_train, X_test, y_train, y_test = make_data_for_lstm(X_data, Y_data,
hist_window, horizon, nb_train, n)
print(X train.shape)
print(y train.shape)
print(X test.shape)
print(y test.shape)
(11950, 30, 77)
(11950, 5, 1)
```

```
(2986, 30, 77)
(2986, 5, 1)
batch size = 256
buffer size = 150
train data = tf.data.Dataset.from tensor slices((X train, y train))
train data =
train data.cache().shuffle(buffer size).batch(batch size).repeat()
val data = tf.data.Dataset.from tensor slices((X test, y test))
val data = val data.batch(batch size).repeat()
lstm model = tf.keras.models.Sequential([
    tf.keras.layers.Bidirectional(tf.keras.layers.LSTM(200,
return sequences=True),
                                input shape=X train.shape[-2:]),
    tf.keras.layers.Dense(20, activation='tanh'),
    tf.keras.layers.Bidirectional(tf.keras.layers.LSTM(150)),
    tf.keras.layers.Dense(20, activation='tanh'),
    tf.keras.layers.Dense(20, activation='tanh'),
    tf.keras.layers.Dropout(0.25),
    tf.keras.layers.Dense(units=horizon),
])
lstm model.compile(optimizer='adam', loss='mse')
lstm model.summary()
Model: "sequential"
                             Output Shape
Layer (type)
                                                        Param #
                                                      ========
bidirectional (Bidirectional (None, 30, 400)
                                                        444800
                             (None, 30, 20)
dense (Dense)
                                                        8020
bidirectional 1 (Bidirection (None, 300)
                                                        205200
dense 1 (Dense)
                             (None, 20)
                                                        6020
dense 2 (Dense)
                             (None, 20)
                                                        420
dropout (Dropout)
                              (None, 20)
                                                        0
dense 3 (Dense)
                              (None, 5)
                                                        105
Total params: 664,565
Trainable params: 664,565
Non-trainable params: 0
model path = 'Bidirectional LSTM Multivariate.h5'
early stopings = tf.keras.callbacks.EarlyStopping(monitor='val loss',
min delta=0, patience=10, verbose=1, mode='min')
```

```
checkpoint = tf.keras.callbacks.ModelCheckpoint(model path,
monitor='val loss', save best only=True, mode='min', verbose=0)
callbacks=[early_stopings,checkpoint]
# Entraînement du modèle, environ 50 minutes pour les 50 epoques si
lancé sur colab, temps relativement long
# Avoir un meilleur processeur et/ou une carte graphique on devrait
pouvoir l'entraîner bien plus rapidement
history = lstm model.fit(train data,epochs=50,steps per epoch=100,
                         validation data=val data, validation steps=50,
                         verbose=1, callbacks=callbacks)
plt.figure(figsize=(16,9))
plt.plot(history.history['loss'])
plt.plot(history.history['val loss'])
plt.title('Model loss')
plt.ylabel('loss')
plt.xlabel('epoch')
plt.legend(['train loss', 'validation loss'])
plt.show()
data val = X scaler.fit transform(data)
val rescaled = data val.reshape(1, data val.shape[0],
data val.shape[1])
pred = lstm model.predict(val rescaled)
pred Inverse = Y scaler.inverse transform(pred)
print(pred Inverse)
```